Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»



Рубежный контроль №2

по дисциплине «Методы машинного обучения»

Выполнил: студент группы ИУ5-23М Дин Но

Краткое описание набора данных

Набор данных 20 групп новостей представляет собой набор из примерно 20 000 документов групп новостей, распределенных (почти) равномерно по 20 различным группам новостей. Насколько мне известно, первоначально она была собрана Кеном Лэнгом, вероятно, для его Newsweeder: Learning to filter netnews paper, хотя он явно не упоминает об этой коллекции. Коллекция 20 групп новостей стала популярным набором данных для экспериментов в текстовых приложениях методов машинного обучения, таких как классификация текста и кластеризация текста.

Импорт Наборов данных

```
import numpy as np
from sklearn.datasets import fetch_20newsgroups
from sklearn.feature_extraction.text import CountVectorizer,TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.svm import SVC
```

Поскольку количество наборов данных 20 классов слишком велико, а стоимость обучения слишком высока, я выбрал 7 из 20 классов, чтобы поэкспериментировать с более типичными категориями.

Примеры в наборе данных

Train:

Test:

```
From: bradelatinet.com (Brad Templeton)\nSubject Re: Dorothy Denning opposes Clipper, Capstone wiretap chips\nOrganization: ClariNet Communications Corp.\nTorn remetrigatesaak.shearson.com (Perry E. Metrger\nSubject: Re: Screw the people crypto is for hard-core hackers 4 spooks only\nOrganization: Partnership 'From: PETCHByyg14.gvg.tek.com (Chuck\\nSubject: Daily Verse\nLines: 4\n\nBut you will receive power when the Holy Spirit comes on you; and you will behamy with 'From: perceive power when the Holy Spirit comes on you; and you will behamy with 'From: perceive power when the Holy Spirit comes on you; and you will behamy with 'From: spirit comes on you; and you will behamy with 'From: spirit comes on you; and you will behamy with 'From: spirit comes on you; and you will behamy with 'From: spirit comes on you; and you will behamy with 'From: spirit comes on you; and you will behamy will be hamy will be the people of the your will be hamy will be the your will be hamy will be ham? 'From: spirit comes on you; and you will beham will be ham? 'From: spirit comes on you; and you will beham will be hamy will be ham? 'From: spirit comes on you; and you will beham will be ham? 'From: spirit comes on you; and you will beham? 'From: spirit comes on you; and you will beham? 'From: promessation to the property of the your will be ham? 'From: promessation to the your will be ham? 'From: promessation to the your will be ham? 'From: promessation to the your will be and the your will be ham? 'From: promessation to the your will be ham? 'Fro
```

Векторизация данных статьи

```
vectorizer1 = TfidfVectorizer(stop_words='english',lowercase=True)
vectorizer2 = CountVectorizer(stop_words='english',lowercase=True)
train1_v=vectorizer1.fit_transform(train.data)
train2_v=vectorizer2.fit_transform(train.data)
print(train1_v.shape)

test1_v=vectorizer1.transform(test.data)
test2_v=vectorizer2.transform(test.data)
print(test1_v.shape)

(3983, 40980)
(2652, 40980)
```

LinearSVC И Multinomial Naive Bayes (MNB)

```
from sklearn.metrics import accuracy score, fl score
clf 1=MultinomialNB(alpha=0.1, fit prior = False)
clf_1.fit(train1_v,train.target)
pred_1=clf_1.predict(test1_v)
print(f1_score(test.target,pred_1,average='macro'))
print(accuracy_score(test.target,pred_1))
0.7991295102257887
0.807315233785822
clf 2=MultinomialNB(alpha=0.1,fit prior = False)
clf_2.fit(train2_v,train.target)
pred 2=clf 2.predict(test2 v)
print(f1 score(test.target,pred 2,average='macro'))
print(accuracy_score(test.target,pred_2))
0.809256244555425
0.8122171945701357
clf 3=SVC()
clf_3.fit(train1_v,train.target)
pred 3=clf 3.predict(test1 v)
print(f1_score(test.target,pred_3,average='macro'))
print(accuracy_score(test.target,pred_3))
0.789824680407716
0.7967571644042232
clf 4=SVC()
clf 4.fit(train2 v,train.target)
pred 4=clf 4.predict(test2 v)
print(f1 score(test.target,pred 4,average='macro'))
print(accuracy score(test.target,pred 4))
0.6205553116107276
0.610105580693816
```

Вывод

Мы видим, что точность составляет до 81,22%. При использовании классификатора MNB и использовании метода CountVectorizer для векторизации объектов.