Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»



Рубежный контроль №2

по дисциплине «Методы машинного обучения»

Выполнил: студент группы ИУ5-23М Дин Но

Краткое описание набора данных

Набор данных 20 групп новостей представляет собой набор из примерно 20 000 документов групп новостей, распределенных (почти) равномерно по 20 различным группам новостей. Насколько мне известно, первоначально она была собрана Кеном Лэнгом, вероятно, для его Newsweeder: Learning to filter netnews paper, хотя он явно не упоминает об этой коллекции. Коллекция 20 групп новостей стала популярным набором данных для экспериментов в текстовых приложениях методов машинного обучения, таких как классификация текста и кластеризация текста.

Импорт Наборов данных

```
import time
t0=time.time()
print('starting time:',time.strftime('%H:%M:%S',time.localtime(time.time())))
import numpy as np
from sklearn.datasets import fetch_20newsgroups
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.svm import SVC
starting time: 16:04:50
```

Поскольку количество наборов данных 20 классов слишком велико, а стоимость обучения слишком высока, я выбрал 7 из 20 классов, чтобы поэкспериментировать с более типичными категориями.

Примеры в наборе данных

Train:

```
"From: c4455858mizzoul.missouri.edu (John Kelsey)\nSubject: Re: How large are commercial keys?\nNntp-Posting-Host: mizzoul.missouri.edu\nOrganization: University impaul@unl.edu (marxhausen paul)\nSubject: Re: "National repentance"\nOrganization: University of Nebraska--Lincoln\nLines: 37\n\nmcovingt&aisun3.ai.uga.
From: mikepyrdo.UUCP (Mike Whitman)\nSubject: 49cm Womens bike for sale\nOrganization: Pyramid Technology, Government Systems\nLines: 29\n\n1 have the follow
"From: picklacca.mmsu.edu (Entropic Destroper\nSubject: Re: Need info on 43:1 ad suicide for refutation\nOrganization: New Mexico State University\nLines: 26
"From: hallefrobecca.its.rpi.edu (Erra D.B. Hall)\nSubject: Re: Receiver and C-10! equilizer for sale\nKeywords: receiver, equilizer ,sterio,amp\nArticle-I.D.:
"From: picklacca.mmsu.edu (Eara D.B. Hall)\nSubject: Re: SUPER REGA AUTOMOBILE SIGHTIN(s]!!!!! Exotics together!\nArticle-I.D.:
"From: xx1558\frac{1}{2}\n\ny \text{u.edu} (Family Magazine Sysops)\nSubject: WITNESS & PROOF OF CHRISTY'S RESURRECTION\nReply-To: xx1558\frac{1}{2}\n\ny \text{u.edu} (Family Magazine Sysops)\nSubject: WITNESS & PROOF OF CHRISTY'S RESURRECTION\nReply-To: xx1558\frac{1}{2}\n\ny \text{u.edu} (Family Magazine Sysops)\nOrdation: Ferom: ricky#ustson.ibm.com (Rick Turner)\nSubject: Re: images of earth\nDisclaimer: This posting represents the poster\'s views, not necessarily those of IBM.

'From: ricky#ustson.ibm.com (Rick Turner)\nSubject: Re: images of earth\nDisclaimer: This posting represents the poster\'s views, not necessarily those of IBM.

'Froot/scikit_learn_data/20news_home/20news-bydate-train/alt.atheism/53070',

'froot/scikit_learn_data/20news_home/20news-bydate-train/soc.religion.christian/2033',

'froot/scikit_learn_data/20news_home/20news-bydate-train/soc.religion.christian/20734',

'froot/scikit_learn_data/20news_home/20news-bydate-train/soc.religion.christian/20556'],

'target': array([0, 5, 1, ..., 0, 5, 5]),

'target_nordata/ representation of the following the following the following the followin
```

Test:

```
'From: brad@clarinet.com (Brad Templeton)\nSubject: Re: Dorothy Denning opposes Clipper, Capstone wiretap chips\nOrganization: ClariNet Communications Corp.\nL
'From: pmetzger@snark.shearson.com (Perry E. Metzger)\nSubject: Re: Screw the people. crypto is for hard-core hackers & spooks only\nOrganization: Partnership
'From: pmetzger@snark.shearson.com (Denve\nSubject: Daily Verse\nLines: 4\n\nBut you will receive power when the Boly Spirit comes on you; and you will behany wit
'From: burgindralph.cs.haverford.edu (Joshus Marc Burgin)\nSubject: FOR SALE - GRAPHIC EQUALIZER\nOrganization: Haverford College Computer Science Department\'
'From: technichtedex'0300.weber.edu (Clarke Whitehead)\nSubject: Re: Berland CH. 3.1 w/App Framer's ** FORSALE **\nNews-Software: VAK/VMS VMFWS: 1.41
'Norgan
'From: mmerv!mozart.cc.iup.edu (Mail Server)\nSubject: Re: Eternal Marriage\nlines: 31\n\n\n hall@vice.ico.tek.com (Haif F. Lillywhite) writes:\n>in article May
'From: standamsdehnewsee.ch.atl.com (David L. Pope)\nSubject: Re: Clipper considered harmful\nOrganization: DST/USCRPACNLnines: 20\n\n\nn Thin\n\n in the Interval Norganization (David L. Pope)\nSubject: Re: Clipper considered harmful\nOrganization: DST/USCRPACNLnines: 20\n\n\n Attr\\n\n\n atticle May
'From: randemSchnewsee.ch.atl.com (David L. Pope)\nSubject: Re: Clipper considered harmful\nOrganization: Project GLUE, University of Maryland, College Park'n
'From: randemSchnewsee.ch.atl.com (David L. Pope)\nSubject: Re: Clipper considered harmful\nOrganization: Project GLUE, University of Maryland, College Park'n
'From: zhongelpi.fdo.nlos.gl.fidonet.org (Alan Olsen)\nSubject: Re: Clipper considered harmful\nOrganization: Project GLUE, University of Maryland, College Park'n
'From: zhongelpi.fdo.nlos.gl.fidonet.org (Alan Olsen)\nSubject: Re: Clipper considered harmful\nOrganization: Project GLUE, University of Maryland, College Park'n
'From: indingle college Park'n
'From: indingle college Park'n
'From: parklege college Parklege Clipper college Parklege Clipper college Par
```

Векторизация данных статьи (алгоритм TF-IDF)

```
vectorizer = TfidfVectorizer(stop_words='english',lowercase=True)
train_v=vectorizer.fit_transform(train.data)
print(train_v.shape)

test_v=vectorizer.transform(test.data)
print(test_v.shape)

(3983, 51826)
(2652, 51826)
```

LinearSVC И Multinomial Naive Bayes (MNB)

```
Classifier = [MultinomialNB(),SVC()]
Classifier str = ['MultinomialNB()','SVC()']
for i in Classifier str:
    t2=time.time()
    model = eval(i)
    model.fit(train_v,train.target)
    print(i+"accuaracy rate:",model.score(test_v,test.target))
    print(i+'how long did it take:%.6fs'%(time.time()-t2))
t1=time.time()
print('the end time of the program:',time.strftime('%H:%M:%S',time.localtime(time.time())))
print("how long did it take: %.2fs"%(t1-t0))
MultinomialNB()accuaracy rate: 0.9170437405731523
MultinomialNB()how long did it take:0.022391s
SVC()accuaracy rate: 0.9147812971342383
SVC()how long did it take:30.537010s
the end time of the program: 16:49:48
how long did it take: 38.00s
```

Вывод

Мы видим, что когда два метода классификации не задают никаких гиперпараметров, точность MNB и SVC одинакова, из которых MNB работает лучше, коэффициент точности составляет 91,7%. Однако разница во времени между запуском MNB и SVC особенно велика. Время работы SVC более чем в тысячу раз превышает время работы MNB.

Таким образом, для этого набора данных, с точки зрения экономии и точности и т. Д., MNB лучше.